POI vadászat szolgáltatói honlapokról

#POI #webscraping #adatok #Python

OpenStreetMap Meetup
2018. június 25.

Szalai Kálmán
@kami911kami

HA LENNE 10.000 FORINTOM,
Az előző rész tartalmából
MEGVEHETNÉM A GÉPHEZ EZT AZ ÚJ,
EREDETI MICROSOFT WINDOWS 95 PROGRAMOT

Ezeket terveztem

- Új adatok gyűjtése (POI)
  - Boltok, áruházláncok
  - Bankok
  - Éttermek, és étteremláncok
- Meglévő POI-k egységesítése
  - Azonos írásmód
  - Azonos kategória
  - Wiki oldal → közösen összeállítani
- Azonosítási mechanizmus, szabály
  - Elegendő-e az OSM ID, vagy valami ref:* szükséges

A POI-k fontosak

- Sokszor van rá szükség
- Keresés
- Meglévő POI-k
  - Sokszor kevés adat
  - Nincs fent minden POI
  - Nem egységesek a nevek

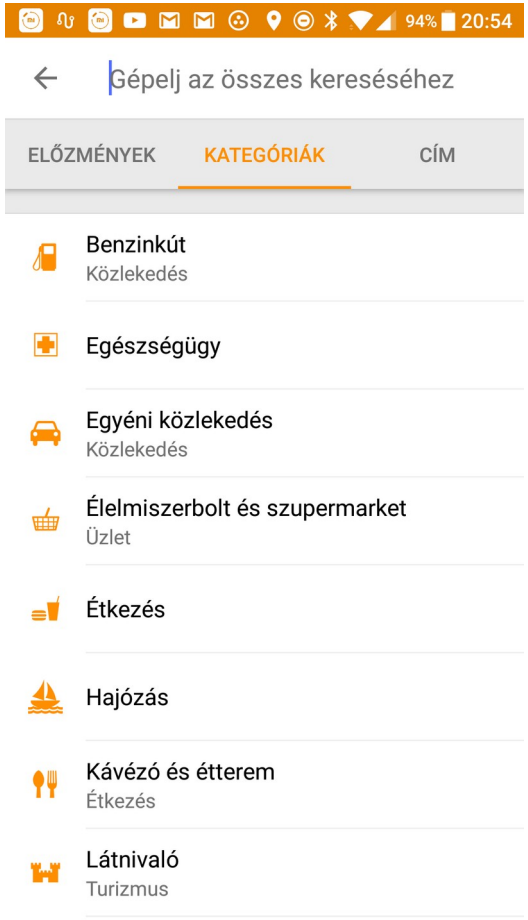

Minden tökéletes, lehet nyugodtan aludni :)

Sokszor kevés adat I

shop=convenience

A convenience store

Áttekintés | Kombinációk | Térkép | Wiki | Projects

Kombinációk

Ez a táblázat csak a leggyakoribb címkék leggyakoribb kombinációit mutatja.

Oldal 1 / 31 JSON Elemek megjelenítve 1 - 14, összesen 432

Darab →		Más címkék	→ Darab	
7 397	86.75%	name=*	7 397	1.85%
5 195	60.92%	source=*	5 195	1.33%
3 243	38.03%	wheelchair=*	3 243	14.89%
3 160	37.06%	fixme=*	3 160	7.90%
3 093	36.27%	source=route4u	3 093	33.70%
2 978	34.92%	fixme=verify	2 978	33.09%
1 959	22.97%	url=*	1 959	3.13%
1 941	22.76%	source=turistautak.hu	1 941	2.06%
1 838	21.56%	source:date=*	1 838	3.60%
1 360	15.95%	wheelchair=no	1 360	17.54%
1 180	13.84%	wheelchair=yes	1 180	12.43%
1 137	13.33%	toilets:wheelchair=*	1 137	18.09%
879	10.31%	addr:street=*	879	0.42%
861	10.10%	addr:postcode=*	861	0.38%

Sokszor kevés adat II

amenity=pharmacy

A shop where a pharmacist sells medications

Áttekintés | Kombinációk | Térkép | Wiki | Projects

Kombinációk

Ez a táblázat csak a leggyakoribb címkék leggyakoribb kombinációit mutatja.

Oldal 1 / 20 JSON Elemek megjelenítve 1 - 14, összesen 273

Darab →		Más címkék	→ Darab	
1 225	70.28%	name=*	1 225	0.31%
602	34.54%	addr:postcode=*	602	0.26%
601	34.48%	addr:street=*	601	0.28%
598	34.31%	addr:city=*	598	0.27%
566	32.47%	addr:housenumber=*	566	0.31%
506	29.03%	opening_hours=*	506	4.22%
379	21.74%	wheelchair=*	379	1.74%
371	21.29%	source=*	371	0.10%
312	17.90%	url=*	312	0.50%
310	17.79%	source=turistautak.hu	310	0.33%
304	17.44%	source:date=*	304	0.60%
243	13.94%	wheelchair=yes	243	2.56%
227	13.02%	phone=*	227	2.42%
200	11.47%	building=*	200	0.02%

Megszűnt vagy átalakult POI-k

2016. augusztus 1-én az Eni Hungaria Zrt.-t - a kenőanyag üzletág kivételével - megvásárolta a MOL Nyrt., így többé nem része az Eni csoportnak.

- 80 darab
  - https://taginfo.openstreetmap.hu/tags/brand=Agip

Nincs minden POI az OSM-ben

- Nemzeti Dohányboltok
  - 5799 vs. 1597
- K&H bankok és ATM automaták
  - 614 vs. 172
- Nem is lehet :(

Nem egységes elnevezés I

Name tag	Darabszám	Százalék
MOL	319	0.08%
Mol	35	0.01%

Nem egységes elnevezés II

Name tag	Darabszám	Százalék
OTP␣Bank	304	0.08%
OTP	195	0.05%
OTP␣ATM	25	0.01%
OTP␣bankautomata	8	0.00%
OTP␣Bank␣+␣ATM	6	0.00%
OTP␣Bankomat␣ATM	5	0.00%
OTP␣Bankautomata	5	0.00%
OTP␣Ingatlanpont	5	0.00%
OTP␣bank	4	0.00%
OTP␣Bank␣és␣ATM	3	0.00%
otpbank␣ATM	3	0.00%
OTP␣Bank␣ATM	2	0.00%
OTP␣-␣ATM	2	0.00%

Szolgáltatói adatok

- Benzinkutak
  - Avia, Shell, OMV, MOL
- Gyógyszertárak:
  - Benu, Kulcs
- Posták, Posta Pontok, csomagautomaták, csekkautomaták
- Boltok
  - CBA, Príma, dm, Rossmann, Spar, Tesco
- Bankok és ATM-ek
  - K&H
- Egyebek
  - Foxpost, MOL Bubi

POI aratás

Bemeneti adatok I

- Weben elérhető adatok
  - Posta Partner Extra
    - XML
      - Településnevek és irányítószámok
      - Közterület nevek
    - https://www.posta.hu/partnerextra
  - Szolgáltatói adatok
    - JavaScript var
    - JSON
    - CSV
    - XML

Bemeneti adatok II

- Weben elérhető adatok
  - OpenStreetMap API
    - OsmApi Python modul
  - OpenStreetMap dump
    - http://download.geofabrik.de/europe/hungary.html
    - osm2pgsql → PostgreSQL, PostGIS betöltés
    - Egyedi stílusfájl alapján

POI kereső

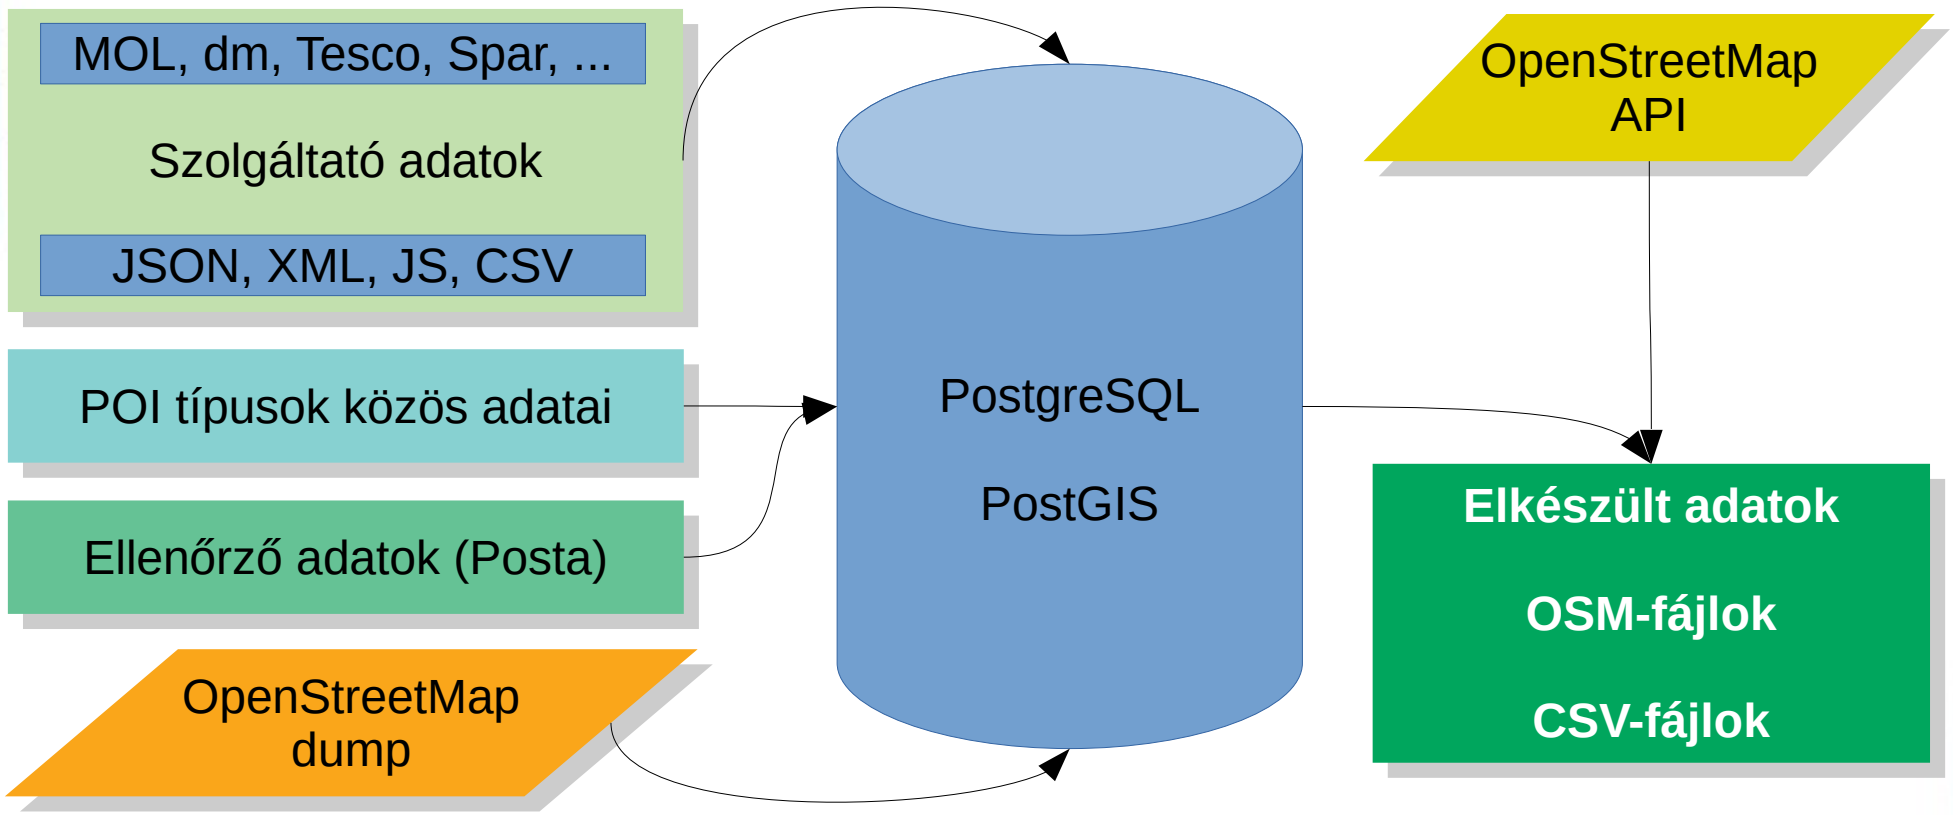
MOL, dm, Tesco, Spar, ...
Szolgáltató adatok
JSON, XML, JS, CSV
POI típusok közös adatai
Ellenőrző adatok (Posta)
OpenStreetMap dump
PostgreSQL
PostGIS
OpenStreetMap API
Elkészült adatok
OSM-fájlok
CSV-fájlok

Mi kell hozzá?

- Python (3.6.5)
- PostgreSQL (10.4) / PostGIS (2.4)
- Python modulok
- Virtualenv
- Egy adatbázis
  - PostGIS extension
  - osm2pgsql
    - osm2pgsql/default.style
  - numpy >= 1.13.0
  - osmapi
  - pandas >= 0.23.1
  - geopandas == 0.3.0
  - scipy == 0.19.0
  - requests
  - bs4
  - sqlalchemy
  - geoalchemy2
  - psycopg2-binary
  - xlrd

```
osm2pgsql -c -m -s -d poi -C 8000 -U poi -W –style
osm2pgsql/default.style --extra-attributes -H
localhost ~/hungary-latest.osm.pbf
```

https://github.com/KAMI911/osm_poi_matchmaker

Futtatás

- app.conf

  # Database settings

  db.type=postgresql

  db.write.host=localhost

  db.write.port=5432

  db.write.username=poi

  db.write.password=*****

  db.poi.database=poi

- python3 ./create_db.py

Statisztikák

- Jelenlegi POI-k száma
  - 6956 darab
- Ebből az OSM-ben
  - 30 méteres körzetben keresve
  - 2233 darab
- vagy
  - 70 méteres körzetben keresve
  - 3228 darab

Houston, we have a problem

cÍmEK

- BERCSÉNYI U.1 2934/5 HRSZ
- BATTHYÁNY TÉR 5-6, Bp. Batthyány tér 5-6
- 9737 Bük, 0131/3 hrsz.
- Kaszás u. 2.-Dózsa György út 87.
- Rétköz u.10/b. (volt Nagyszeben tér)
- 9653 Répcelak, 076/15. hrsz 86. számú főút mellett
- CSIPKEGYÁRI UTCA 11., Győr,Csipkegyári utca 11.
- Zalai u.2. (Szarvas Gábor u.33)
- Pécs, belterület

Koordináták

- Felcserélt koordináták
- Rossz koordináták:

„furcsa MOL tankhajó
a földközi tengeren”

Visszajelzések I

„Köszönettel vettük egyes MOL-töltőállomások nem megfelelő koordinátáira vonatkozó észrevételét.

A hibás paramétereket illetékes kollégáink javították rendszerünkben.

Jelzését köszönjük, és bármely további kérdés, észrevétel esetén készséggel állunk rendelkezésére ügyfélszolgálatunk elérhetőségein!”

Visszajelzések II

- „Jelzése alapján, az állományok javításra kerültek. Amennyiben további hibát, pontatlanságat talál, akkor azt kérjük Ügyfélszolgálatunkon keresztül jelezze, és javítjuk.”

- „Észrevételét illetékes munkatársak részére továbbítottuk.”

Bejövő adatok

- osm_poi_matchmaker/dataproviders

- hu_aldi.py
- hu_avia.py
- hu_benu.py
- hu_cba.py
- hu_cib_bank.py
- hu_dm.py
- hu_foxpost.py
- hu_generic.py
- hu_kh_bank.py
- hu_kulcs_patika.py
- hu_mol.py
- hu_mol_bubi.py
- hu_omv.py
- hu_penny_market.py
- hu_posta.py
- hu_rossmann.py
- hu_shell.py
- hu_spar.py
- hu_tesco.py
- hu_tom_market.py

Adattárolás

- poi_common
  - Közös adatok
    - Név
    - Közös tag-ek
    - Kategóriák
      - Amenity
      - Shop
    - Kapcsolati címek
    - Alap URL
- poi_address
  - A POI adatai
  - Cím → city tábla
  - Branch
  - Nyitvatartás
  - URL kiegészítés

POI-k felkutatása

POI-k felkutatása

- Koordináta alapján
- Azonos kategória
- 70 méteres körzetben
  - Konfigurációs fájlból konfigurálható
- Node, ha még nincs
- Ha létezik, akkor a már meglévő frissítése
  - Node
  - Way

hutescosup?

Do You Speak This Language?

huaviafu hubenupha hububibir hucbacon hudmche hufoxpocso hukhatm hukhbank hukulcspha humobpefu humolfu huomvfu hupostacse hupostacso hupostapo hupostapp huprimacon hurossmche hushellfu husparexp husparint husparsup hutescoexp hutescoext hutescosup

Azonosítók

huaviafu hubenupha hububibir hucbacon hudmche
hufoxpocso hukhatm hukhbank hukulcspha
humobpefu humolfu huomvfu hupostacse
hupostacso hupostapo hupostapp huprimacon
hurossmche hushellfu husparexp husparint
husparsup hutescoexp hutescoext hutescosup

hu tesco sup

Hungary Tesco Supermarket

Hogyan segíthetsz?

Hogyan segíthetsz?

- Kimeneti fájlok átnézése, ellenőrzése, javítása
  - https://github.com/KAMI911/osm-import-data/tree/master/hu-poi-data
- Hibás bemeneti adatok felkutatása
- Javaslatok további közös kulcs-érték párokra
- Hibák jelentése
- Újabb bemeneti adatok felkutatása
- Importálók készítése
- Javítások és tesztek készítése
- Továbbfejlesztés

Továbbfejlesztési lehetőségek

Továbbfejlesztési lehetőségek

- POI-k azonosítása
  - Közös ID
  - Cím alapján képzett SHA512 hash (?)
- Okosabb POI azonosítási eljárás
- POI koordináták gyorsítótárazása
- POI attribútumok gyorsítótározása
- További attribútumok tárolása és feldolgozása

Kérdések

Köszönöm a figyelmet!

Szalai Kálmán (KAMI)
@kami911kami

This work is licensed under a Creative Commons Attribution-ShareAlike 3.0 Unported License.

SlideShare:

Képek

- http://images2.fanpop.com/image/photos/13900000/Cute-Dog-Wallpaper-dogs-13936344-1024-768.jpg
- http://barkpost.com/wp-content/uploads/2013/09/Tennis-Ball-for-Dogs-1.jpg
- https://upload.wikimedia.org/wikipedia/commons/2/23/Rostov%27s_region_combain.jpg
- https://commons.wikimedia.org/wiki/File:Rostov%27s_region_combain.jpg
- https://cdn.pixabay.com/photo/2016/03/10/22/23/lettuce-1249414_960_720.jpg
- https://hu.m.wikipedia.org/wiki/F%C3%A1jl:Dart